Wdrażanie i ocena skuteczności systemu biometrycznego twarzy

Bartosz Tramś 268421

Bartosz Mila 246706

Krzysztof Szydłowski 171562

Termin zajęć 10.04.2026 17:05

1. Cel pracy i zakres eksperymentów

Celem projektu było zbudowanie i przetestowanie systemu autoryzacji użytkownika na podstawie biometrii twarzy. Wykorzystano gotową implementację modelu rozpoznawania twarzy bez dodatkowego treningu lub dostrajania. Zakres pracy obejmował zarówno przygotowanie bazy wdrożeniowej, jak i serię testów odporności systemu na typowe zakłócenia obrazu.

Weryfikację przeprowadzono zgodnie z wymaganiami zadania: zbadano skuteczność systemu na zbalansowanym zbiorze prób genuine i impostor, wpływ osób niewdrożonych, odporność na szum, zmiany luminancji i kompresję JPEG, a także czasy działania najważniejszych operacji. Po stronie raportowej nacisk położono na spójne przedstawienie wyników, porównanie z przypadkiem bazowym oraz praktyczną analizę błędów.

2. Metoda autoryzacji i implementacja systemu

Do ekstrakcji reprezentacji twarzy użyto biblioteki DeepFace z modelem ArcFace. Z pojedynczego obrazu twarzy generowany jest 512-wymiarowy embedding, który następnie porównywany jest z embeddingiem zapisanym w bazie użytkowników. Jako miarę podobieństwa zastosowano podobieństwo kosinusowe.

W procesie wdrożenia użytkownika wykorzystywana jest funkcja enroll(image_path, user_id), która lokalizuje twarz, wyznacza embedding i zapisuje go w bazie database/embeddings.pkl. W procesie autoryzacji funkcja verify(image_path, claimed_id) oblicza embedding obrazu zapytania, pobiera embedding deklarowanej tożsamości i na tej podstawie zwraca score oraz decyzję binarną po porównaniu z ustalonym progiem decyzyjnym.

Rozwiązanie ma charakter 1:1, to znaczy odpowiada na pytanie, czy obraz należy do użytkownika, za którego dana osoba się podaje. Dodatkowo oszacowano czas identyfikacji 1:N poprzez porównanie embeddingu zapytania z całą bazą wdrożonych profili.

3. Zbiór danych, podział oraz profile zespołu

Do eksperymentów wykorzystano podzbiór CelebA oraz własne fotografie członków zespołu. Gotowy model nie był dalej trenowany, dlatego kluczowy był rozłączny podział danych pomiędzy próbki wdrożeniowe i próbki używane do testowania.

Tabela 1 przedstawia liczność podzbiorów po rozszerzeniu danych o trzy profile ręczne.

Podzbiór	Liczba obrazów	Liczba tożsamości
enrollment	83	83
genuine_test	362	83
impostor_pool	1478	83
unknown_user	457	20

Łącznie wdrożono 83 tożsamości, z czego 80 pochodziło ze zbioru CelebA, a 3 odpowiadały członkom zespołu. Zbiór testowy zawierał 506 prób, w tym 253 prób genuine i 253 prób impostor.

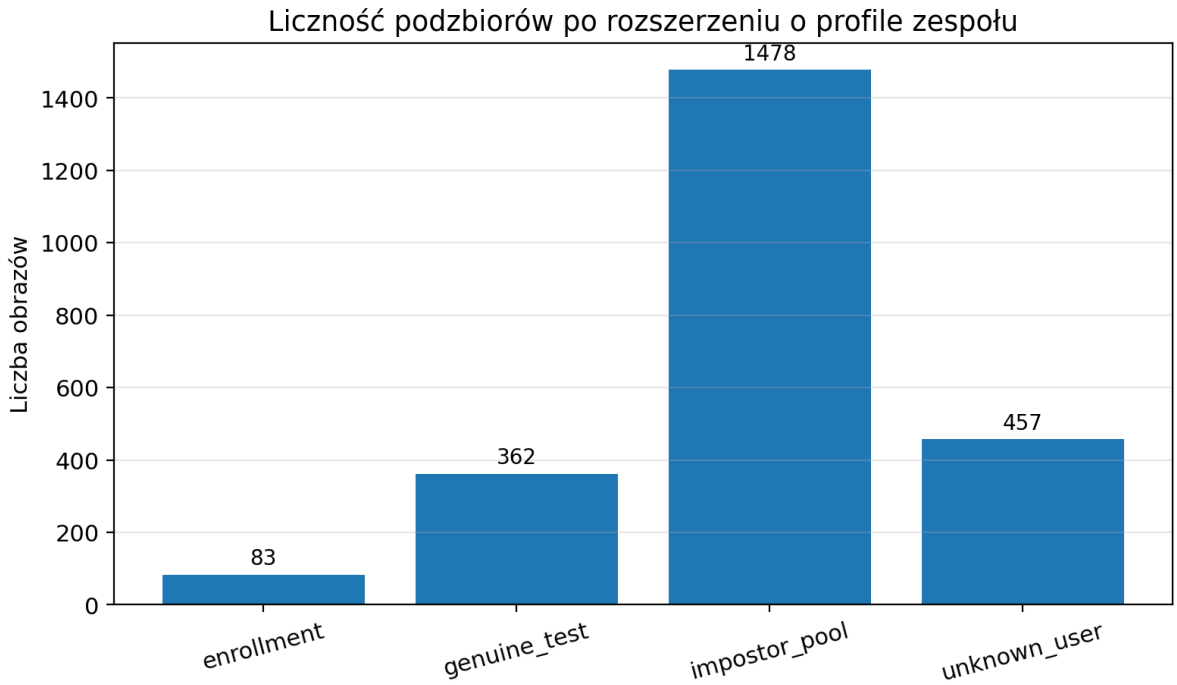

Rysunek 1. Liczność podzbiorów po rozszerzeniu danych o trzy profile członków zespołu.

Dla zdjęć członków zespołu przyjęto prosty schemat zgodny z wymaganiami zadania: zdjęcie z indeksem 1 wykorzystano do wdrożenia, zdjęcie z indeksem 2 do próby genuine, a zdjęcie z indeksem 3 do próby impostor. W celu zachowania spójności typów danych w plikach CSV ręcznym profilom nadano numeryczne identyfikatory 90001–90003, a mapowanie do nazwisk przechowano w osobnym pliku pomocniczym.

Tabela 2. Profile ręczne dodane do systemu.

Tożsamość	Identyfikator	Podział zdjęć 1/2/3
Bartosz Tramś	90001	1 → enrollment, 2 → genuine, 3 → impostor
Bartosz Mila	90002	1 → enrollment, 2 → genuine, 3 → impostor
Krzysztof Szydlowski	90003	1 → enrollment, 2 → genuine, 3 → impostor

4. Procedura wdrożenia, autoryzacji oraz przechowywania danych

Każdemu wdrożonemu użytkownikowi przypisano pojedynczy embedding wyznaczony na podstawie jednego obrazu enrollmentowego. Rozwiązanie upraszcza bazę danych, ale jednocześnie zwiększa wrażliwość systemu na zmianę pozy, oświetlenia i jakości zdjęcia. Weryfikacja wykonywana jest z użyciem pojedynczego obrazu zapytania.

W bazie nie są przechowywane surowe zdjęcia wdrożeniowe użytkowników, lecz wyłącznie embeddingi zapisane w pliku database/embeddings.pkl. Jest to rozwiązanie bezpieczniejsze od przechowywania obrazów, ale nadal należy traktować embedding jako dane biometryczne. W razie wycieku możliwe jest powiązanie wektora z konkretną osobą lub jego wykorzystanie do nieautoryzowanej analizy porównawczej.

Ryzyko systemowe dotyczy przede wszystkim retencji danych, możliwości ich dalszego kopiowania oraz faktu, że reprezentacja biometryczna nie może zostać 'zmieniona' przez użytkownika tak łatwo jak hasło. Z tego powodu praktyczne wdrożenie takiego systemu powinno obejmować ograniczenie dostępu do bazy, kontrolę czasu przechowywania danych oraz usuwanie nieużywanych profili.

5. Wynik bazowy oraz wybór progu decyzyjnego

Najpierw przeprowadzono eksperyment bazowy na 506 próbach autoryzacji, w tym 253 próbach genuine i 253 próbach impostor. Na podstawie rozkładu score oraz analizy ROC wybrano próg pracy systemu równy 0.1443.

Zbiór	Threshold	FAR	FRR	TAR
Baseline (506 prób)	0.1443	12.65%	12.65%	87.35%

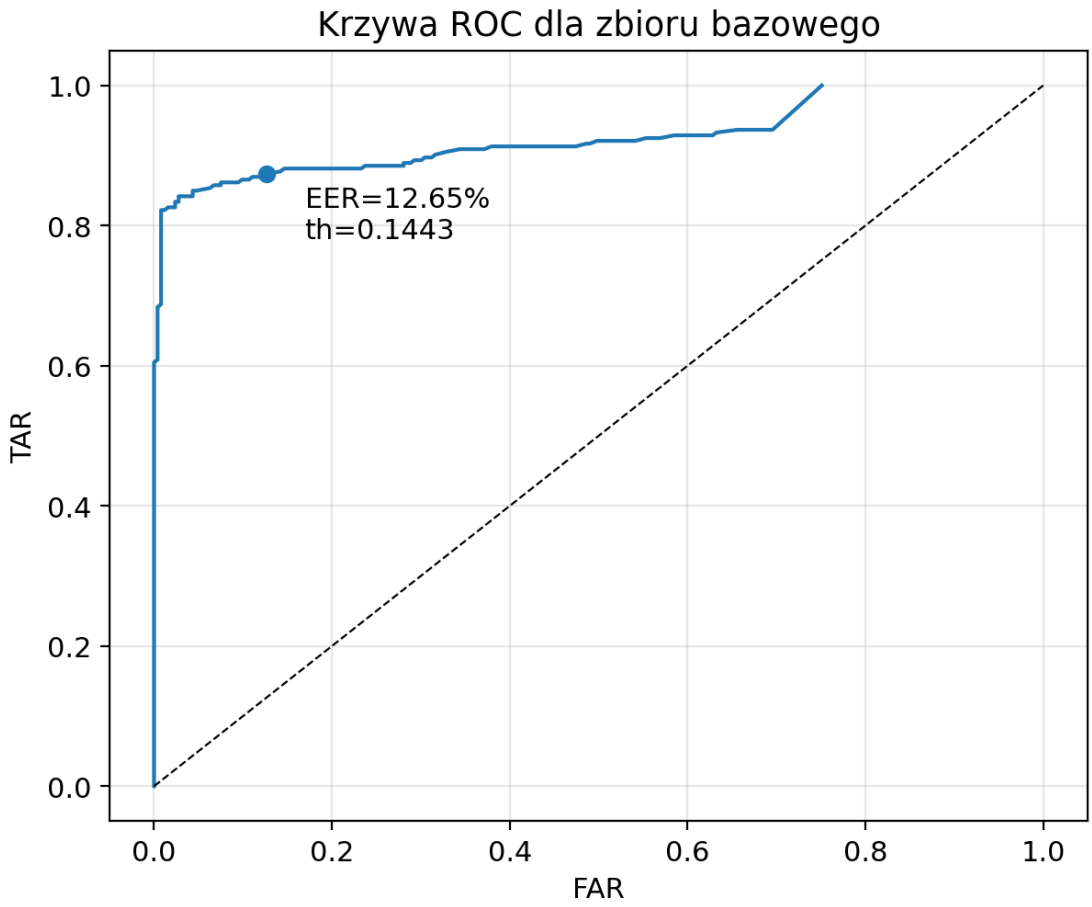

Rysunek 2. Krzywa ROC dla zbioru bazowego z zaznaczonym punktem EER.

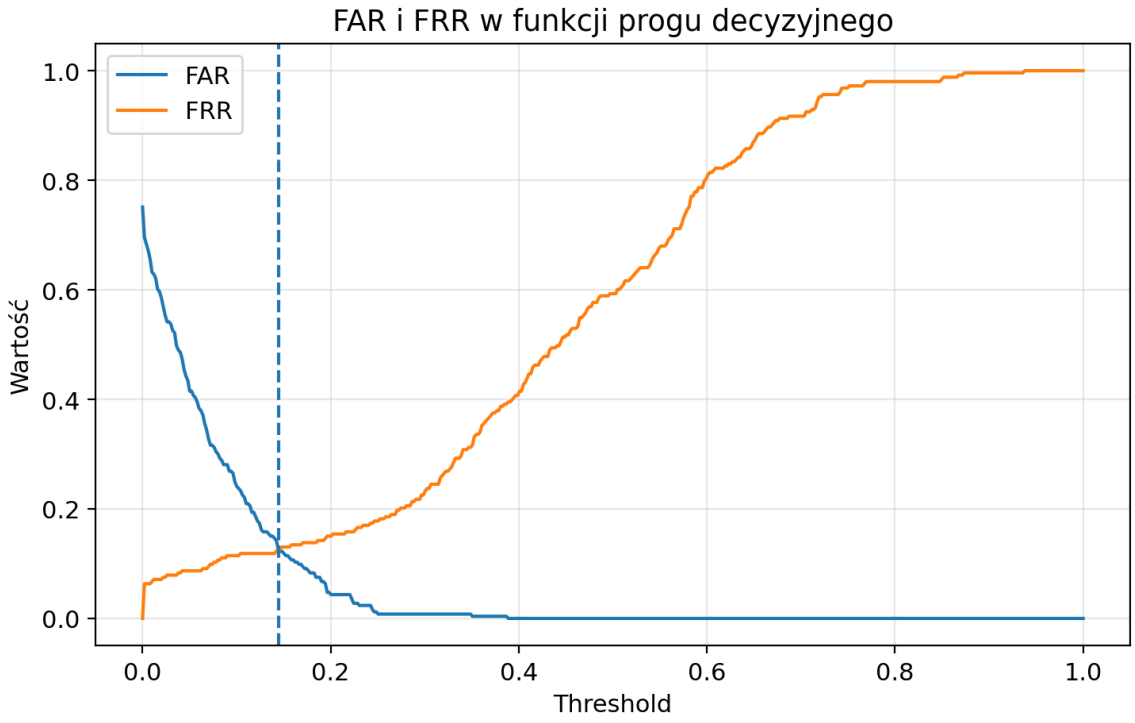

Rysunek 3. Zależność FAR i FRR od progu decyzyjnego.

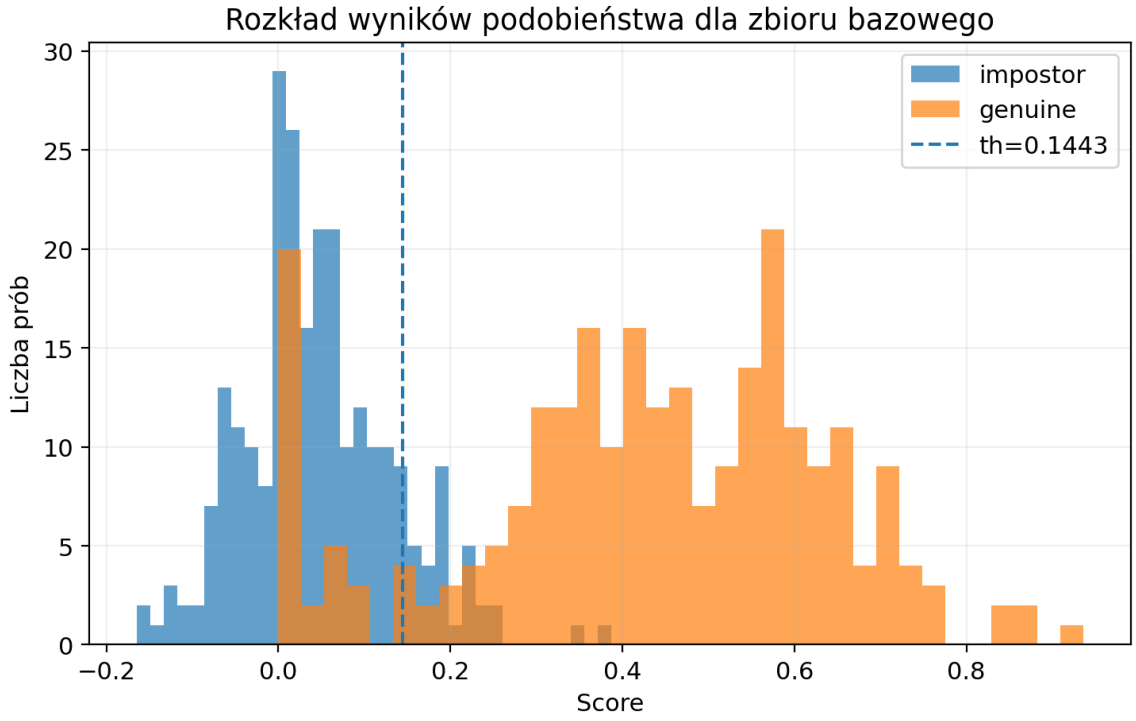

Rysunek 4. Rozkład score dla prób genuine i impostor w zbiorze bazowym.

Punkt EER wyniósł 12.65%, a odpowiadający mu próg pozostał taki sam jak przed rozszerzeniem danych zespołu. W porównaniu z wynikami raportowanymi dla ArcFace na standardowych benchmarkach referencyjnych uzyskany wynik jest wyraźnie słabszy, co nie jest zaskoczeniem: w niniejszym projekcie użyto pojedynczego obrazu enrollmentowego, gotowej implementacji bez dostrajania oraz dodatkowych testów na danych o zróżnicowanym charakterze, a nie na ściśle kontrolowanym benchmarku.

6. Wpływ osób niewdrożonych

W drugim eksperymencie sprawdzono, czy dołączenie 100 zdjęć osób niewdrożonych do puli prób negatywnych wpływa na częstość błędnych akceptacji. Ponieważ dla takich prób nie istnieje klasa genuine, analizie poddano wyłącznie FAR/FPR.

Zbiór	Liczba prób	FAR
baseline	506	12.65%
unknown	100	13.00%
baseline + unknown	606	12.75%

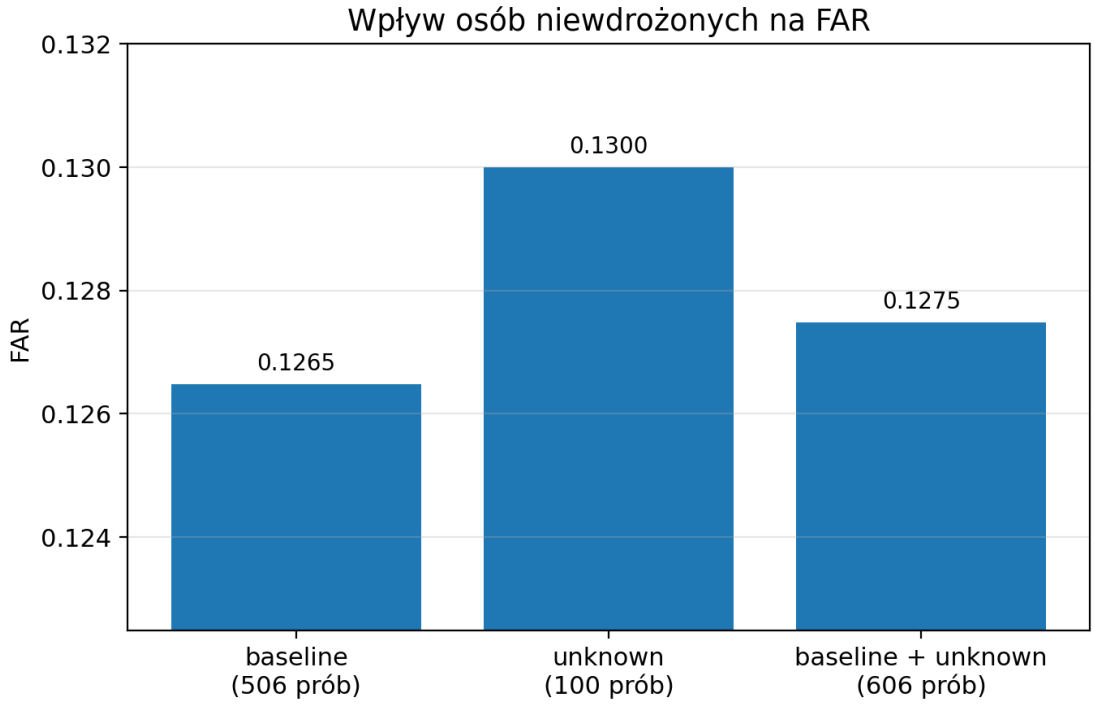

Rysunek 5. Porównanie FAR dla przypadku bazowego oraz wariantów z udziałem osób niewdrożonych. Oś Y została zawężona, aby uwidocznić małe różnice między wariantami.

Po dodaniu osób niewdrożonych FAR wzrósł z 12.65% do 13.00% dla samego zbioru unknown oraz do 12.75% dla połączonego zbioru baseline + unknown. Zmiana była niewielka, co sugeruje, że problemem systemu są przede wszystkim pomyłki wewnątrz populacji wdrożonych profili, a nie masowe błędne akceptowanie twarzy spoza systemu

7. Praktyczna analiza błędów systemu

Po rozszerzeniu zbioru testowego odnotowano 32 false accepts i 32 false rejects. W tabeli poniżej zebrano cztery reprezentatywne przypadki: dwa błędne zaakceptowania impostora i dwa błędne odrzucenia użytkownika. Dla czytelności pokazano zarówno obraz zapytania, jak i obraz referencyjny z bazy.

Typ błędu	Obraz zapytania	Obraz referencyjny	Score / próg	Krótka diagnoza
False Accept	178457.jpg	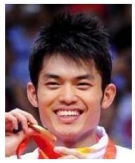 190011.jpg	score = 0.3870 threshold = 0.1443 true = 4069 claimed = 5872	Wysoki score dla pary impostor.
False Accept	ks3.jpg	tr1.jpg	score = 0.2435 threshold = 0.1443 true = Krzysztof Szydlowski claimed = Bartosz Trams	Przypadek z udziałem profili ręcznych.
False Reject	110509.jpg	010150.jpg	score = 0.0000 threshold = 0.1443 true = 8834 claimed = 8834	Score równy 0,0; prawdopodobna porażka detekcji lub ekstrakcji embeddingu.
False Reject	087573.jpg	021895.jpg	score = 0.0000 threshold = 0.1443 true = 9688 claimed = 9688	Score równy 0,0; prawdopodobna porażka detekcji lub ekstrakcji embeddingu.

Na uwagę zasługuje przypadek false accept z udziałem profili ręcznych: obraz Krzysztofa Szydłowskiego został błędnie zaakceptowany jako profil Bartosza Tramsia. W przypadku false reject dominują przypadki ze score równym 0.0. Oznacza to, że część błędów odrzucenia nie wynika z podobieństwa twarzy do niewłaściwej klasy, ale z wcześniejszej porażki etapu detekcji lub ekstrakcji embeddingu.

8. Odporność na zakłócenia obrazu

8.1. Szum Gaussa

Badanie szumu przeprowadzono dla pięciu przedziałów PSNR, każdorazowo na 300 losowo wybranych zdjęciach. Oceniano wpływ degradacji obrazu na FAR, FRR i TAR przy stałym progu 0.1443.

Pasmo PSNR	FAR	FRR	TAR
50-80 dB	11.11%	11.56%	88.44%
40-50 dB	12.42%	12.24%	87.76%
30-40 dB	13.07%	10.88%	89.12%
20-30 dB	12.42%	10.20%	89.80%
10-20 dB	17.65%	15.65%	84.35%

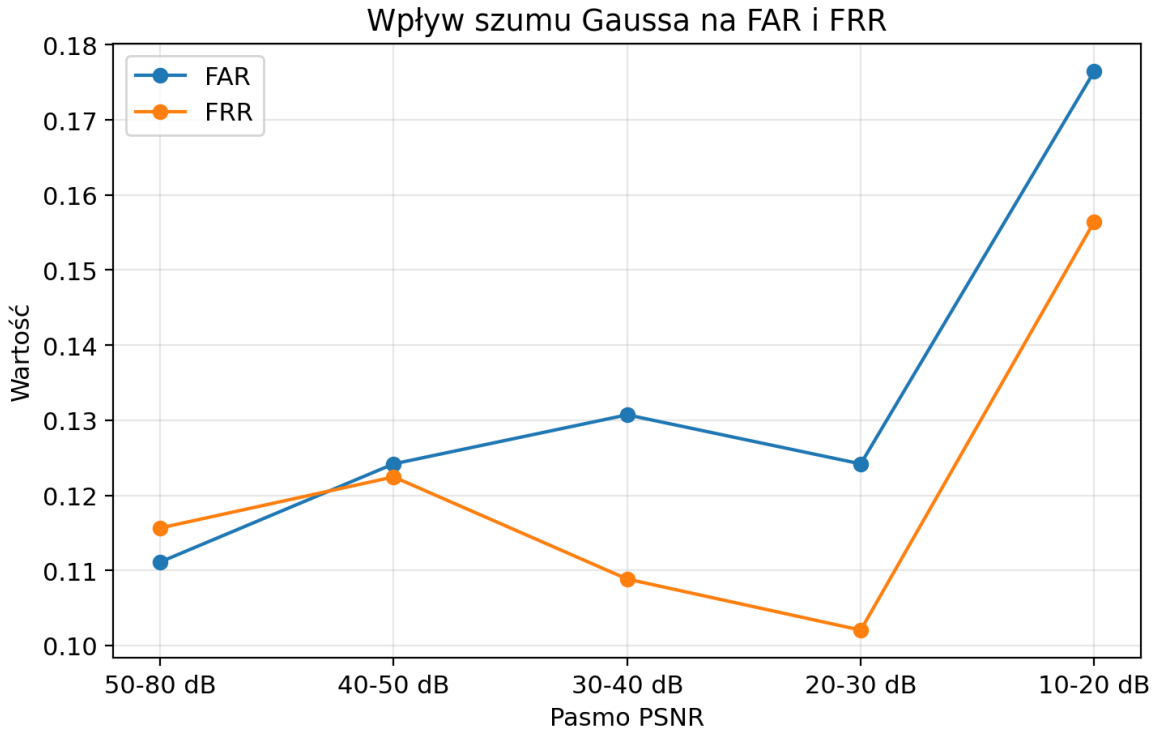

Rysunek 6. Wpływ szumu Gaussa na FAR i FRR.

Największe pogorszenie jakości nastąpiło dla przedziału 10–20 dB, gdzie FAR wzrósł do 17.65%, a FRR do 15.65%. Dla słabszego szumu wynik był zbliżony do przypadku bazowego, a miejscami nawet minimalnie lepszy, co można wiązać z losowym doborem podzbiorów i niewielką skalą różnic.

8.2. Zmiany luminancji

W testach luminancji przeskalowano lub przesunięto kanał jasności, zachowując informację o chrominancji. Sprawdzono zarówno transformację kwadratową, jak i skale liniowe oraz przesunięcia o stałą wartość.

Wariant	FAR	FRR	TAR
quadratic	12.65%	14.23%	85.77%
linear x0.5	13.83%	11.46%	88.54%
linear x0.6	14.62%	12.25%	87.75%
linear x0.75	14.23%	12.25%	87.75%
linear x1.33	10.67%	10.67%	89.33%
linear x1.5	11.86%	14.23%	85.77%
offset -100	12.25%	19.37%	80.63%
offset -20	11.86%	11.46%	88.54%
offset -10	12.65%	11.46%	88.54%
offset +30	12.25%	11.46%	88.54%

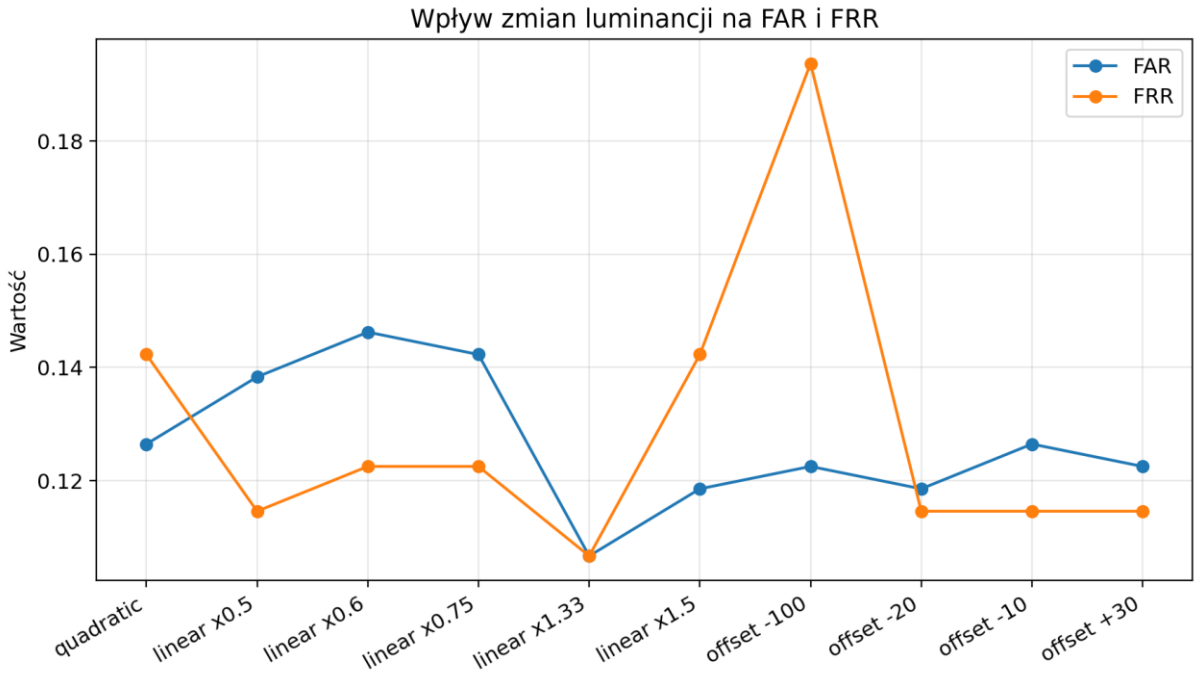

Rysunek 7. Wpływ zmian luminancji na FAR i FRR.

Najbardziej niekorzystny okazał się wariant offset -100, dla którego FRR wzrósł do 19.37%. Oznacza to, że silne przyciemnienie znacznie częściej prowadziło do odrzucenia prawidłowego użytkownika. Z drugiej strony umiarkowane rozjaśnienie (linear x1.33) dało najlepszy wynik spośród wszystkich wariantów luminancji i poprawiło jednocześnie FAR oraz FRR względem przypadku bazowego.

8.3. Kompresja JPEG

Wpływ kompresji JPEG zbadano dla pięciu poziomów jakości. Celem było sprawdzenie, czy strata informacji o wysokiej częstotliwości i artefakty blokowe wpływają na skuteczność rozpoznawania.

Jakość JPEG	FAR	FRR	TAR
q=95	11.46%	11.86%	88.14%
q=75	12.65%	12.25%	87.75%
q=50	14.62%	13.04%	86.96%
q=35	13.04%	12.65%	87.35%
q=20	14.62%	11.46%	88.54%

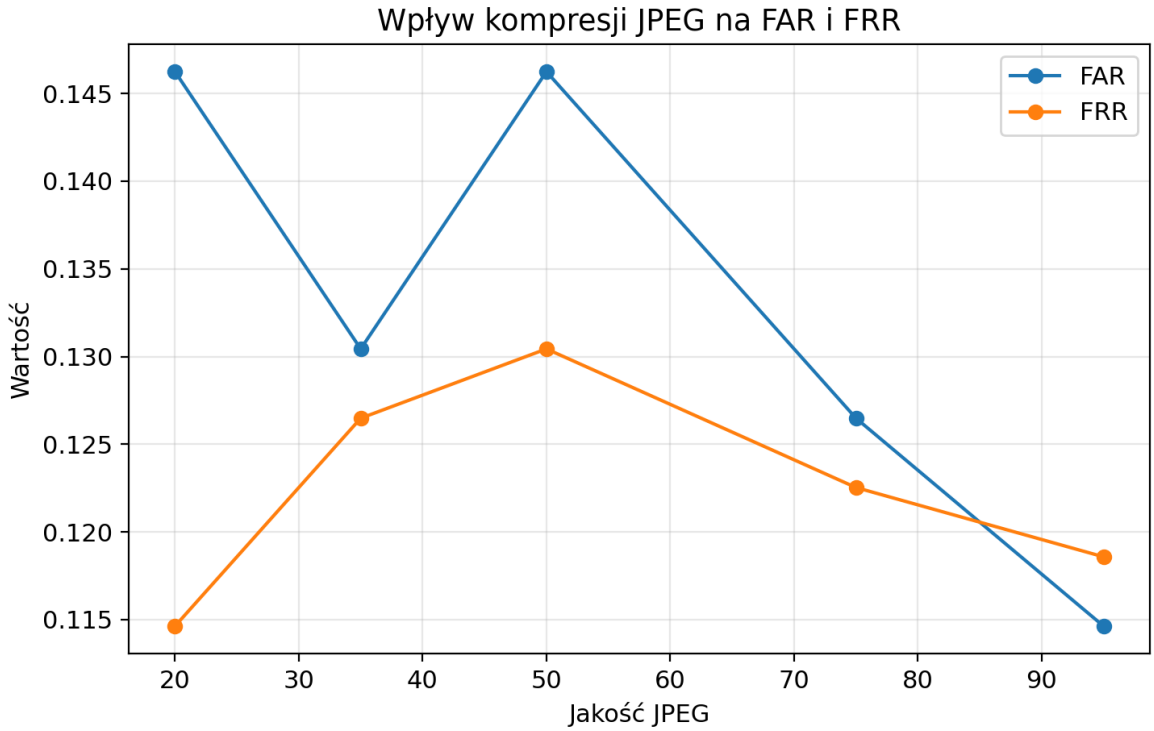

Rysunek 8. Wpływ kompresji JPEG na FAR i FRR.

Dla wysokiej jakości kompresji (q=95) wynik był bardzo zbliżony do przypadku bazowego. Widoczne pogorszenie pojawiło się dopiero przy niższych jakościach, szczególnie dla q=50 i q=20, gdzie FAR wzrósł do 14.62%. Oznacza to, że umiarkowana kompresja jest dla systemu akceptowalna, ale silna kompresja zwiększa liczbę błędnych akceptacji.

9. Analiza czasowa

Zmierzono czas wdrożenia nowego użytkownika, pojedynczej weryfikacji 1:1 oraz identyfikacji 1:N. Pomiary wykonano z użyciem time.perf_counter(). Dla enrollmentu użyto kopii bazy, tak aby sam eksperyment nie zmieniał finalnego stanu systemu.

Operacja	n	Średnia [s]	Mediana [s]	Min [s]	Max [s]
enrollment	20	0.9135	0.2888	0.2608	12.7897
verify 1:1	100	0.1930	0.2085	0.0148	0.2404
identify 1:N	100	0.1801	0.2078	0.0144	0.2283

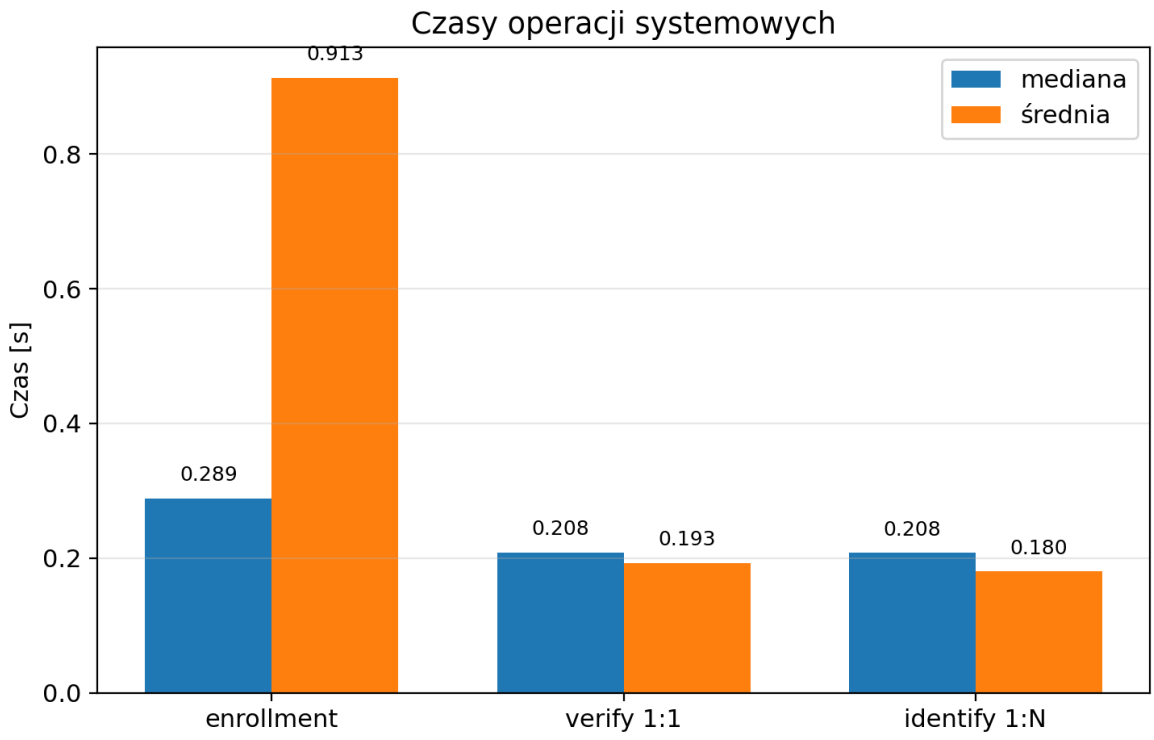

Rysunek 9. Porównanie średnich i median czasów operacji systemowych.

W przypadku enrollmentu widoczny był pojedynczy koszt inicjalizacji modelu, co zawyżyło średnią do 0.9135 s. Z tego powodu za bardziej reprezentatywną miarę uznano medianę, równą 0.2888 s. Czasy verify 1:1 i identify 1:N okazały się bardzo zbliżone; dla bazy 103 profili koszt samego porównania embeddingów jest niewielki względem kosztu ich wyznaczenia.

10. Wnioski końcowe

Zbudowany system poprawnie realizuje dwa podstawowe zadania projektowe: umożliwia wdrażanie nowych użytkowników i autoryzację na podstawie obrazu twarzy. Po rozszerzeniu danych o trzy profile zespołu baza zawiera 83 tożsamości, a wszystkie wymagane eksperymenty zostały przeprowadzone na finalnym stanie systemu.

Wynik bazowy systemu można uznać za umiarkowanie dobry: przy progu 0.1443 uzyskano FAR = 12.65%, FRR = 12.65% i TAR = 87.35%. Największą słabością okazały się silne degradacje obrazu, zwłaszcza bardzo duży szum oraz skrajne przyciemnienie. Jednocześnie umiarkowana kompresja JPEG i obecność osób niewdrożonych nie zmieniły wyników w sposób drastyczny.

Praktyczna analiza błędów pokazała, że false accept i false reject mają różne źródła. Dla części false acceptów problemem jest podobieństwo embeddingów między różnymi osobami, natomiast w false rejectach często występuje score równy 0.0, co wskazuje na porażkę wcześniejszego etapu detekcji lub ekstrakcji reprezentacji. W dalszych pracach jako naturalny kierunek ulepszeń można wskazać zastosowanie większej liczby obrazów enrollmentowych na osobę, ujednolicenie backendu detekcji oraz bardziej konsekwentne filtrowanie jakości zdjęć wejściowych.